

Laboratório 2: Limpeza e Transformação de Dados

Nícolas Rosenthal Dal Corso

April 9, 2026

Contents

1	Introdução	2
2	Inspeção Inicial	2
3	Etapas de Limpeza	2
3.1	Remoção de Duplicatas	2
3.2	Padronização de Texto	2
3.3	Tratamento de Idades Inválidas	3
3.4	Conversão e Padronização de Datas	3
3.5	Tratamento de Valores Ausentes	3
4	Transformações Realizadas	3
5	Outliers	4
6	Dataset Final	4

1 Introdução

O objetivo deste trabalho foi transformar um dataset com problemas de qualidade em um conjunto de dados limpo, consistente e adequado para análise.

O dataset original apresentava problemas típicos de dados reais, incluindo:

- valores duplicados
- inconsistência em texto (nomes e categorias)
- idades inválidas
- valores ausentes
- possíveis outliers em renda

2 Inspeção Inicial

A análise inicial mostrou:

- duplicatas exatas (ex: registros repetidos de clientes)
- nomes com capitalização inconsistente (ex: "carla")
- idades inválidas (ex: 200 anos)
- possíveis inconsistências em categorias como cidade e gênero

3 Etapas de Limpeza

3.1 Remoção de Duplicatas

Registros duplicados foram removidos para evitar viés estatístico.

3.2 Padronização de Texto

As colunas textuais foram normalizadas:

- nomes capitalizados corretamente
- categorias padronizadas (ex: gênero e cidade)

3.3 Tratamento de Idades Inválidas

Idades irreais (ex: > 100 ou negativas) foram substituídas por valores ausentes (NaN), evitando distorções na análise.

3.4 Conversão e Padronização de Datas

A coluna `signup_date` foi convertida para formato `datetime`, tratando múltiplos formatos de entrada.

3.5 Tratamento de Valores Ausentes

Foi adotada a seguinte estratégia:

- variáveis numéricas: preenchidas com a mediana
- variáveis categóricas: preenchidas com "Desconhecido"

4 Transformações Realizadas

Foram criadas novas variáveis para enriquecer o dataset:

- `signup_month`: mês de cadastro extraído da data
- `income_minmax`: normalização da renda (escala 0-1)
- `income_log`: transformação logarítmica para reduzir assimetria
- `segment_encoded`: codificação numérica da variável categórica
- `purchases_per_age`: razão entre compras e idade
- `income_per_purchase`: renda média por compra

Além disso, a variável categórica `city` foi transformada usando one-hot encoding, gerando colunas como:

- `city_Porto Alegre`
- `city_São Paulo`
- `city_Rio de Janeiro`
- `city_Curitiba`
- `city_Desconhecido`

5 Outliers

Foi identificado um valor de renda potencialmente extremo.

Optou-se por manter o valor, aplicando transformação logarítmica (`income_log`), pois:

- a remoção poderia descartar informação relevante
- a transformação reduz o impacto do outlier sem perder o dado

6 Dataset Final

O dataset final contém:

- dados limpos e consistentes
- variáveis transformadas relevantes
- codificação adequada para modelos de machine learning

O conjunto final possui 21 colunas, incluindo variáveis derivadas e codificadas.